OpenAI Platform

Tokenizador

Aprenda sobre tokenização de modelos de linguagem

Os grandes modelos de linguagem da OpenAI processam texto usando **tokens** , que são sequências comuns de caracteres encontradas em um conjunto de texto. Os modelos aprendem a entender as relações estatísticas entre esses tokens e se destacam na produção do próximo token em uma sequência. Saber mais.

Você pode usar a ferramenta abaixo para entender como um trecho de texto pode ser tokenizado por um modelo de linguagem e a contagem total de tokens nesse trecho de texto.

GPT-5.x e O1/3 | GPT-4 e GPT-3.5 (legado) | GPT-3 (legado)

Many words map to one token, but some don't: indivisible.

Unicode characters like emojis may be split into many tokens containing the underlying bytes: 🖐🏾

Sequences of characters commonly found next to each other may be grouped together: 1234567890

Claro | Mostrar exemplo

Fichas 53

Personagens 252

Muitospalavrasmapaparaumtoken,masalgunsnão:indivíduoé possível.

Unicodepersonagenscomoemojispoderiaserdividiremmuitosfichascontendoosubjacente bytes:🖐🏾

Sequênciasdepersonagensgeralmenteencontradopróximoparacadaoutropoderiaser agrupadosjunto: 1234567890

Texto | IDs de token

Uma regra prática útil é que um token geralmente corresponde a cerca de 4 caracteres de texto em inglês comum. Isso se traduz em aproximadamente ¾ de uma palavra (portanto, 100 tokens são aproximadamente 75 palavras).

Se você precisa de uma interface programática para tokenizar texto, confira nossa solução. token do tiktoken pacote para Python. Para JavaScript, o pacote com suporte da comunidade. @dbdq/tiktoken O pacote funciona com a maioria dos modelos GPT.